

SISTEMATIZAÇÃO MEC – Laboratório Estatístico Interativo

Identificação e links do projeto

Nome do grupo	DataLab
Aluna	Luana Oliveira de Jesus
Matrícula	72650514

Links do Projeto

Link do repositório GitHub	https://github.com/luanaoj-arch/Sistematizacao/tree/main
Link dataset	https://www.kaggle.com/datasets/nicapotato/womens-ecommerce-clothing-reviews?resource=download
Link da aplicação	Streamlit
Link do vídeo	N/A

Resumo

Dataset escolhido: foi utilizado o dataset Women's E-Commerce Clothing Reviews, disponível no Kaggle. O conjunto possui avaliações de clientes sobre roupas femininas e contém 23.486 registros e 11 colunas. Foram analisadas variáveis como idade, avaliação, recomendação e quantidade de feedbacks positivos.

Módulos implementados: o projeto foi desenvolvido em Python utilizando Streamlit. Foi criada uma biblioteca estatística própria, chamada minhastats.py, com funções de média, mediana, moda, amplitude, variância, desvio padrão, percentil, quartis, coeficiente de variação, covariância, correlação de Pearson e regressão linear. Também foram desenvolvidos testes automatizados comparados com resultados do NumPy. A aplicação apresenta estatística descritiva, simulações de Monte Carlo, uma simulação relacionada ao Teorema Central do Limite, comparações com distribuições teóricas, correlação, regressão linear, predição interativa e um resumo das principais descobertas.

Descrição do Projeto Individual:

O projeto Laboratório Estatístico Interativo foi desenvolvido em Python e Streamlit.

A aplicação utiliza dados reais para realizar cálculos estatísticos, gráficos e simulações de forma interativa.

DataSet: Women's E-Commerce Clothing Reviews

Link:

<https://www.kaggle.com/datasets/nicapotato/womens-ecommerce-clothing-reviews?resource=download>

Instrução de instalação do Projeto:

Para desenvolver o projeto, foi preciso realizar a instalação VS na máquina local, realizar todas as configurações necessárias e executar comandos das bibliotecas necessárias (pandas, numpy, streamlit e etc...).


Execução do projeto:

Para iniciar a aplicação, foi necessário executar o comando abaixo no terminal:

```
python -m streamlit run app.py
```

Após isso, era possível visualizar a aplicação diretamente no navegador.

Capturas de tela da aplicação funcionando.



← ↻ localhost:8501

Verifique se é você

Deploy

Laboratório Estatístico Interativo

Bem-vindo ao laboratório estatístico de Luanaaaaaaa!

Módulo 2 - Estatística Descritiva

Quantidade de registros: 23486

Dados do arquivo:

	Unnamed: 0	Clothing ID	Age	Title	Review Text
0	0	767	33	None	Absolutely wonderful - silky and s
1	1	1080	34	None	Love this dress! It's sooo pretty. i
2	2	1077	60	Some major design flaws	I had such high hopes for this dres
3	3	1049	50	My favorite buy!	I love, love, love this jumpsuit. It's
4	4	847	47	Flattering shirt	This shirt is very flattering to all du
5	5	1080	49	Not for the very petite	I love tracy reese dresses, but this
6	6	858	39	Cagrcol shimmer fun	I aded this in my basket at hte last
7	7	858	39	Shimmer, surprisingly goes with lots	I ordered this in carbon for store p
8	8	1077	24	Flattering	I love this dress. i usually get an xs
9	9	1077	34	Such a fun dress!	I'm 5'5" and 125 lbs. i ordered the

Escolha uma variável para analisar

Selecione uma variável:

Age

Você escolheu: Age

Resultados estatísticos

Média: 43.198543813335604

Mediana: 41.0

Moda:

[0 : 39]

Amplitude: 81

Desvio padrão amostral: 12.27954361559137


Desvio padrão amostral: 12.27954361559137

Desvio padrão amostral: 12.27954361559137

Tabela de frequência

Classe	Frequência
["left": 17.919, "right": 26.1]	1646
["left": 26.1, "right": 34.2]	4421
["left": 34.2, "right": 42.3]	6575
["left": 42.3, "right": 50.4]	4516
["left": 50.4, "right": 58.5]	3229
["left": 58.5, "right": 66.6]	2215
["left": 66.6, "right": 74.7]	691
["left": 74.7, "right": 82.8]	112
["left": 82.8, "right": 90.9]	68
["left": 90.9, "right": 99]	13

Gráfico de distribuição



Age

Detecção de outliers (IQR)

Primeiro quartil (Q1): 34.0

Mediana (Q2): 41.0

Terceiro quartil (Q3): 52.0

Intervalo interquartil (IQR): 18.0

Limite inferior: 7.0

Limite superior: 79.0

Quantidade de outliers: 109

Alguns valores identificados:

▼ [

- 0 : 83
- 1 : 83
- 2 : 83
- 3 : 80
- 4 : 93
- 5 : 82
- 6 : 82

Interpretação dos resultados

A média é maior que a mediana, indicando que alguns valores mais altos podem estar influenciando a média.

A variável analisada foi Age. A média encontrada foi 43.20, enquanto a mediana foi 41.00.


O desvio padrão amostral foi 12.28, representando a dispersão dos valores em relação à média.

Foram identificados 109 possíveis outliers pelo método do intervalo interquartil (IQR).

Módulo 3 - Lei dos Grandes Números

Simulação de lançamentos de uma moeda para observar a aproximação da proporção de caras a 50%.

Quantidade de lançamentos:




Quantidade de caras: 498

Proporção de caras: 49.80%

A proporção esperada de caras em uma moeda equilibrada é aproximadamente 50%.

Evolução da proporção de caras



Teorema do Limite Central


Vamos observar a distribuição das médias de várias amostras retiradas de uma população.

Tamanho de cada amostra:

30

Quantidade de amostras:

1000



Resumo das Amostras

Menor média amostral: 44.1

Maior média amostral: 44.1

Desvio padrão completo: 0.0

Interpretação do TLC


A média das médias amostrais foi 44.10.

O desvio padrão das médias amostrais foi 0.00.

O Teorema do Limite Central afirma que, sob condições adequadas, a distribuição das médias amostrais tende a se aproximar de uma distribuição normal conforme o tamanho das amostras aumenta.

Ao aumentar o tamanho da amostra, a variabilidade das médias tende a diminuir, fazendo com que elas se concentrem ao redor da média populacional.

Módulo 4 - Distribuição Normal



Interpretação da Distribuição Normal


A média das idades foi 43.20.

O desvio padrão populacional das idades foi 12.28.

O histograma representa a distribuição das idades observadas no dataset. A curva representa uma distribuição normal teórica calculada usando a média e o desvio padrão dos dados.

Quanto mais o formato dos dados se aproximar da curva, maior será a semelhança visual com a distribuição normal. Essa comparação é apenas descritiva.

Distribuição de Poisson



Discussão do ajuste

Ao comparar o histograma com a distribuição de Poisson, é possível observar visualmente se os dados reais apresentam um comportamento parecido com a curva teórica. Quanto mais semelhantes forem os formatos, melhor será a aproximação. Essa análise é apenas visual e descritiva, não sendo um teste estatístico formal.

Módulo 5 - Correlação e Regressão Linear

Escolha duas variáveis numéricas para analisar.

Selecione a variável X:

Age


Selecione a variável Y:

Rating

Variável X: Age

Variável Y: Rating

Diagrama de dispersão



Coeficiente de correlação de Pearson


Coeficiente de correlação: 0.0268

A correlação é positiva, indicando que as variáveis tendem a aumentar juntas.

Regressão linear simples

Coeficiente linear (intercepto): 4.0913

Coeficiente angular (inclinação): 0.0024



Coeficiente de determinação (R^2)

R^2 : 0.0007

Equação da reta

$\hat{Y} = 4.0913 + 0.0024 \times X$

Predição interativa

Digite um valor de Age:

43,20

- +

Valor estimado de Rating: 4.1960

Interpretação dos resultados

O coeficiente angular é positivo (0.0024). Isso indica uma tendência de aumento de Rating quando Age aumenta.

É importante lembrar que correlação não significa causalidade. Mesmo que duas variáveis apresentem alguma relação, isso não quer dizer que uma delas esteja causando a outra. Por isso, é necessário ter cuidado ao interpretar os resultados.

Módulo 6 - 3 Achados/Descobertas

Nesta etapa, apresento três observações identificadas durante a análise do dataset.

Descoberta 1 - Avaliação das roupas

A média das avaliações das roupas é 4.20.

Esse resultado ajuda a entender como as clientes avaliaram os produtos analisados.

Descoberta 2 - Idade das clientes

A idade média das clientes no dataset é 43.20 anos.

Essa informação permite conhecer melhor o perfil etário das participantes da pesquisa.

Descoberta 3 - Recomendação dos produtos

Aproximadamente 82.24% dos registros indicam recomendação do produto.

Esse percentual mostra a proporção de registros em que o produto foi recomendado.

Três principais descobertas:

1. Avaliação das roupas	A média das avaliações dos produtos foi de 4.20. Esse resultado ajuda a entender como as clientes avaliaram os produtos analisados.
2. Idade das clientes	A idade média das clientes foi de 43.20 anos.

	Essa informação ajuda a conhecer o perfil das participantes da pesquisa e permite compreender melhor a faixa etária presente nos dados.
3. Recomendação dos produtos	Aproximadamente 82.24% dos registros indicam recomendação do produto. Esse percentual mostra a proporção de registros em que o produto foi recomendado, ou seja, mostra a proporção de clientes que recomendaram os produtos e ajuda a compreender o comportamento de recomendação presente no dataset.

Consideração final: O projeto permitiu aplicar conceitos de estatística e programação na análise de dados reais, utilizando uma aplicação interativa para apresentar os resultados.